


Predicción de la Gravedad de de Accidentes de Tráfico en Madrid

Proyecto Final Keepcoding · Ruijia Gu

MACHINE LEARNING · SEGURIDAD VIAL · MADRID 2019–2025



¿Podemos anticipar la gravedad de un accidente?



Este proyecto desarrolla un modelo de Machine Learning capaz de **predecir si un accidente requerirá atención médica**, permitiendo **mejorar la respuesta ante emergencias**.

¿Para qué sirve este modelo?



Objetivo principal

Predecir la gravedad de los accidentes de tráfico en Madrid a partir de variables contextuales, meteorológicas, temporales y características de los implicados.



Gestión de emergencias

Optimizar la asignación de recursos sanitarios y mejorar los tiempos de respuesta ante accidentes.



Planificación urbana

Identificar factores de riesgo y apoyar la toma de decisiones en políticas de seguridad vial.



Conocimiento accionable

Transformar datos históricos en información útil para la toma de decisiones.

Del dato bruto al modelo



Cada fase garantiza la trazabilidad del proceso y la reproducibilidad de los resultados, desde la consolidación de archivos hasta la evaluación final del modelo.

Datos de accidentes y meteorología

1


Accidentes · Ayuntamiento de Madrid

Periodo 2019–2025. Incluye fecha, localización, tipo de accidente, vehículo, tipo de persona y nivel de lesividad.

2

Meteorología · OpenWeather API

Temperatura, precipitación y velocidad del viento. Integrados por fecha y hora exacta de cada accidente.



WEATHER STATION DATA MERGE

Preparación de datos (ETL)

Carga y limpieza

Se consolidaron múltiples fuentes en un único dataset y se realizó la limpieza de datos, eliminando duplicados, tratando valores nulos e inconsistencias y descartando variables con alto porcentaje de datos faltantes.

Tipado y transformación

Se convirtieron las fechas a formato *datetime* y se generaron variables temporales relevantes. Además, las variables categóricas se adaptaron a formatos adecuados para el modelado.

Integración de datos

Se integraron los datos meteorológicos mediante un *merge* por fecha y hora, enriqueciendo cada accidente con su contexto climático y validando la consistencia del dataset final.

Variable objetivo y transformación de datos

Se construye una **variable binaria supervisada** denominada **gravedad** a partir de la variable original de lesividad, simplificando el problema de clasificación.

Clase 0 — No Grave

- Accidentes sin asistencia sanitaria

Clase 1 — Grave

- Asistencia sanitaria en el lugar
- Atención en urgencias
- Asistencia ambulatoria posterior
- Ingreso hospitalario
- Fallecimiento

Transformación del dataset

El dataset original se encontraba a nivel de persona o vehículo, por lo que se realizó una agregación por número de expediente para obtener un registro único por accidente.


Enriquecimiento de variables

Se generaron nuevas variables temporales que aportan contexto al modelo, como festivo, fin de semana, estación, franja horaria y día/noche


Análisis exploratorio

EDA inicial

(1) Dataset desbalanceado



(3) Relación Gravedad de accidentes con clima



(2) Accidentes por hora



(3) Relación Gravedad de accidentes con clima



Identificar los factores que aumentan la probabilidad de accidentes graves en Madrid para mejorar la prevención y asignación de recursos

Total accidentes

67.54 mil

Número de accidentes graves

52 mil

% accidentes graves

0.78

Distribución geográfica de la gravedad de los accidentes en Madrid

gravedad ● 0 ● 1



Conclusiones principales:

Las condiciones meteorológicas adversas aumentan la gravedad de los accidentes.


Los accidentes más graves se asocian a caídas, atropellos y vuelcos.

La gravedad no presenta una concentración geográfica clara en Madrid.

Impacto de las condiciones meteorológicas en la gravedad de los accidentes




Gravedad media de los accidentes según su tipo






Factores clave asociados a la gravedad de los accidentes


Distribución de los vehículos implicados en los accidentes




Gravedad media de los accidentes según consumo de alcohol




Gravedad media de los accidentes según hora punta y días festivos



Gravedad media de los accidentes según tipo de persona involucrada



Gravedad media de los accidentes según tipo de vehículo



Conclusiones principales:

- (1) La gravedad apenas varía según el tipo de vehículo.
- (2) Los accidentes son ligeramente más graves fuera de hora punta y en días no festivos.
- (3) Los peatones, especialmente en atropellos, presentan la mayor gravedad media.
- (4) Los accidentes con alcohol positivo muestran una gravedad media menor que los de alcohol negativo.

Planteamiento de Hipótesis

A partir del análisis exploratorio de los datos, se plantean las siguientes hipótesis que serán contrastadas posteriormente mediante el modelo de Machine Learning:

**Los accidentes con peatones
presentan mayor gravedad**

**El tipo de accidente influye
en la gravedad**

**Las condiciones meteorológicas
aumentan la gravedad**

La hora punta incrementa la gravedad

El consumo de alcohol aumenta la gravedad

Construyendo mejores predictores

Se aplicaron múltiples técnicas para enriquecer el dataset:

→ One-hot encoding

Variables categóricas: estado meteorológico, tipo de accidente, tipo de persona, grupo de vehículo.

→ Variables temporales


Hora punta, fin de semana, festivo, franja horaria, noche, mes y estación.

→ Variables de interacción

noche_x_alcohol, lluvia_x_hora, fin_semana_x_noche, hora_peligrosa.

→ Riesgo espacial (K-Means)

Clustering geográfico para asignar un indicador de riesgo por zona, calculado solo sobre datos de entrenamiento para evitar data leakage.



Modelos utilizados

Random Forest y Gradient Boosting con validación cruzada, ajuste de hiperparámetros, balanceo de clases (SMOTE) y optimización del threshold.

	precision	recall	f1-score	support
0	0.61	0.56	0.58	3012
1	0.88	0.90	0.89	10497
accuracy			0.82	13509
macro avg	0.74	0.73	0.73	13509
weighted avg	0.82	0.82	0.82	13509

Resultados del modelo

0.82

Accuracy global

0.89

F1 clase grave

0.73

F1 macro

Modelo Final: Gradient Boosting

Clase 1 — Accidentes graves

Precision: 0.88 · Recall: **0.90** · F1: 0.89. Alta capacidad de detección.


Clase 0 — No graves

Precision: 0.61 · Recall: 0.56 · F1: 0.58. Margen de mejora en esta clase.



El modelo prioriza correctamente la detección de accidentes graves, minimizando falsos negativos críticos.

¿Qué factores explican la gravedad de los accidentes?



El tipo de vehículo (motocicleta, patinente) y el tipo de implicado (peatón) y son los principales determinantes de la gravedad.

¿Qué confirman los datos?

✓ Peatones → mayor gravedad

Confirmada. Los atropellos presentan los valores más altos de gravedad media.



✓ Tipo de accidente influye

Confirmada. Atropellos, caídas y vuelcos son los más graves. Las motocicletas destacan en importancia.



⚠ Meteorología: efecto parcial

Parcialmente confirmada. Ligera mayor gravedad en lluvia intensa, pero baja importancia en el modelo.

✗ Hora punta no aumenta gravedad

No confirmada. Mayor densidad de tráfico no implica mayor gravedad, posiblemente por velocidades reducidas.



✗ Alcohol: no confirmado en datos

No confirmada. Posible subregistro o sesgo. No descartable en contexto real.

Conclusiones y posibles mejoras

Un modelo sólido con recorrido de mejora

Conclusiones

Modelo sólido y consistente

Factores estructurales como principales determinantes

Margen de mejora en la clasificación

Líneas de mejora

Uso de modelos más avanzados para mejorar el rendimiento.

Enriquecimiento del dataset con nuevas variables contextuales.

Aplicación de validación temporal para mayor robustez.

Evolución hacia una aplicación práctica en entornos reales.

Escalabilidad e integración en entornos productivos



Lessons Learned



Procesamiento de Datos

- Error en la variable de festivo por incompatibilidad de formato
- Importancia de validar formatos antes de integración
- Errores silenciosos afectan la calidad de datos y rendimiento del modelo



Gestión del Desbalanceo y Data Leakage

- SMOTE aplicado inicialmente antes de validación cruzada causaba data leakage
- Corrección: incorporar SMOTE dentro del pipeline de validación cruzada
- Oversampling solo en datos de entrenamiento por iteración
- Garantiza evaluación más realista del modelo



Definición de la Variable Objetivo

- Enfoque inicial: clasificación multiclase (tres niveles de gravedad)
- Problema: dificultad para distinguir entre niveles
- Solución: reformulación a clasificación binaria
- Clase 0: accidentes sin asistencia sanitaria
- Clase 1: accidentes con asistencia sanitaria
- Mejora significativa en rendimiento y valor de negocio



¡Muchas Gracias!

Predicción de la Gravedad de Accidentes de Tráfico en Madrid

Rebeca Ruijia Gu

¿Alguna pregunta? Contacta en: ruijiagu@alumni.ie.edu

Agradezco su atención.