

INFORME TÉCNICO
Predicción de la gravedad de accidentes de tráfico en
Madrid

Proyecto Final Keepcoding

Rebeca Ruijia Gu

Contents

1. Resumen ejecutivo	3
2. Objetivo del proyecto	3
3. Contexto y valor de negocio	3
4. Fuentes de datos.....	3
4.1 Datos de accidentes	3
4.2 Datos meteorológicos.....	4
4.3 Integración de datos.....	4
5. Arquitectura del proyecto	4
6. Preparación de datos (ETL)	5
6.1 Carga de datos.....	5
6.2 Limpieza de datos	5
6.3 Tipado y normalización	5
6.4 Integración de datos meteorológicos	5
6.5 Construcción de la variable objetivo	5
6.6 Transformación a nivel accidente.....	6
6.7 Generación de variables temporales adicionales	6
7. Análisis de correlaciones	6
8. Análisis exploratorio de datos.....	6
9. Visualización de las métricas en Power BI.....	7
10. Planteamiento de hipótesis.....	8
11. Ingeniería de variables	8
12. Modelado	10
13. Evaluación del modelo.....	11
14. Análisis de la matriz de confusión.....	12
15. Validación de hipótesis.....	13
16. Conclusiones	14
17. Posibles mejoras	14
18. Lessons Learned	15

1. Resumen ejecutivo

El presente proyecto tiene como objetivo desarrollar un modelo predictivo capaz de estimar la gravedad de los accidentes de tráfico en la ciudad de Madrid, utilizando técnicas de Machine Learning aplicadas a datos históricos y variables contextuales.

A través de un proceso completo de ingesta, limpieza, transformación, análisis exploratorio y modelado, se ha identificado que los factores con mayor capacidad explicativa de la gravedad de los accidentes están relacionados con el tipo de implicado (especialmente peatones) y el tipo de vehículo (particularmente motocicletas). Por el contrario, variables contextuales como las condiciones meteorológicas, la hora del día o el consumo de alcohol presentan una menor relevancia dentro del conjunto de datos analizado.

El modelo desarrollado presenta un rendimiento satisfactorio en términos globales, si bien muestra limitaciones en la detección de accidentes graves, lo que pone de manifiesto la complejidad del problema y la necesidad de mejoras futuras.

2. Objetivo del proyecto

El objetivo principal del proyecto es predecir la gravedad de los accidentes de tráfico en Madrid a partir de variables relacionadas con el contexto del accidente, las condiciones meteorológicas, el momento temporal y las características de los implicados.

De forma complementaria, se persiguen los siguientes objetivos:

- Identificar los factores que influyen en la gravedad de los accidentes
- Validar hipótesis relacionadas con la seguridad vial
- Generar conocimiento útil para la toma de decisiones en la gestión de emergencias
- Construir un modelo predictivo robusto y evaluable

3. Contexto y valor de negocio

La predicción de la gravedad de los accidentes de tráfico tiene una aplicación directa en la optimización de la gestión de emergencias y en la planificación de políticas de seguridad vial.

En particular, este tipo de modelos permite:

- Mejorar la asignación de recursos sanitarios, como ambulancias y personal médico
- Optimizar los tiempos de respuesta ante incidentes
- Identificar factores de riesgo asociados a accidentes graves
- Apoyar la toma de decisiones en el ámbito de la planificación urbana y la seguridad vial

En este contexto, el valor del proyecto radica en la capacidad de transformar datos históricos en información accionable, contribuyendo a la reducción del impacto de los accidentes.

4. Fuentes de datos

4.1 Datos de accidentes

Los datos de accidentes de tráfico han sido obtenidos del portal de datos abiertos del Ayuntamiento de Madrid.

El dataset utilizado cubre el periodo comprendido entre los años 2019 y 2025, lo que permite disponer de una base de datos amplia y representativa del comportamiento de los accidentes en la ciudad a lo largo del tiempo.

Incluye información detallada sobre:

- Fecha y hora del accidente
- Localización
- Tipo de accidente
- Tipo de vehículo implicado
- Tipo de persona involucrada (conductor, pasajero, peatón)
- Nivel de lesividad

No se han utilizado datos anteriores a 2019, ya que estos se encuentran en un formato estructuralmente distinto, lo que dificulta su integración con el resto del dataset y podría introducir inconsistencias en el análisis. Esta decisión garantiza la homogeneidad de los datos utilizados.

El amplio rango temporal considerado permite reducir el impacto de variaciones puntuales y capturar patrones más estables.

4.2 Datos meteorológicos

Los datos meteorológicos han sido obtenidos mediante la API pública de OpenWeather, un servicio ampliamente utilizado que proporciona acceso gratuito a información climática en tiempo real e histórica.

Esta API permite extraer de forma sencilla y eficiente variables meteorológicas relevantes mediante peticiones HTTP, lo que facilita su integración en procesos de análisis de datos.

En el marco de este proyecto, se han utilizado las siguientes variables:

- Temperatura
- Precipitación
- Velocidad del viento

La elección de OpenWeather se debe a su facilidad de uso, disponibilidad de datos y capacidad de integración directa con herramientas de análisis, lo que ha permitido enriquecer el dataset de accidentes con información climática asociada al momento de cada incidente.

4.3 Integración de datos

La integración de los datos se ha realizado tomando como fuente principal el dataset de accidentes, al cual se han incorporado las variables meteorológicas.

El proceso de unión se ha llevado a cabo mediante un *merge* basado en la fecha y la hora del accidente, permitiendo asignar a cada registro las condiciones climáticas correspondientes en el momento exacto de su ocurrencia.

De este modo, cada accidente queda enriquecido con información contextual adicional, manteniendo la estructura original del dataset de accidentes y evitando la pérdida de registros. Este enfoque garantiza que el análisis y el modelado se realicen sobre una base de datos coherente y alineada temporalmente.

5. Arquitectura del proyecto

El proyecto se estructura en las siguientes fases:

1. Ingesta de datos
2. Limpieza y preprocesamiento
3. Transformación y generación de variables (ETL)
4. Análisis exploratorio de datos (EDA)

5. Modelado
6. Evaluación

Este enfoque permite garantizar la trazabilidad del proceso y la reproducibilidad de los resultados.

6. Preparación de datos (ETL)

6.1 Carga de datos

Se consolidan múltiples archivos de datos en un único dataset, asegurando la consistencia estructural.

6.2 Limpieza de datos

Se han realizado las siguientes operaciones:

- Eliminación de registros duplicados
- Análisis y tratamiento de valores nulos
- Eliminación de variables con alto porcentaje de datos faltantes
- Tratamiento de valores desconocidos o inconsistentes

Este proceso permite mejorar la calidad del dataset y reducir el ruido en el modelado.

6.3 Tipado y normalización

Se han corregido los tipos de datos:

- Conversión de fechas a formato datetime
- Extracción de variables temporales (año, mes, día de la semana)
- Conversión de variables categóricas a formatos adecuados

6.4 Integración de datos meteorológicos

Se ha realizado la integración de datos mediante un proceso de unión por fecha y hora, validando la consistencia de los registros resultantes.

6.5 Construcción de la variable objetivo

Para abordar el problema como una tarea de clasificación supervisada, se ha construido una variable objetivo binaria denominada "gravedad", a partir de la variable original de lesividad.

Se han definido dos clases:

Clase 0 (no grave):

- Accidentes sin asistencia sanitaria

Clase 1 (grave):

- Accidentes con asistencia sanitaria en el lugar
- Atención en urgencias
- Asistencia ambulatoria posterior
- Ingreso hospitalario
- Fallecimiento

Se han excluido registros con valores desconocidos o no válidos en la variable de lesividad.

Esta transformación permite simplificar el problema y facilitar su modelado, centrándose en la distinción entre accidentes con impacto relevante y aquellos de menor severidad.

6.6 Transformación a nivel accidente

El dataset original se encontraba parcialmente a nivel de persona o vehículo. Se ha realizado una agregación por número de expediente para obtener un dataset a nivel de accidente.

6.7 Generación de variables temporales adicionales

Se han generado nuevas variables, tales como:

- Indicador de festivo
- Fin de semana
- Estación del año
- Franja horaria
- Día o noche

Estas variables permiten capturar patrones temporales relevantes.

7. Análisis de correlaciones

El análisis de correlaciones muestra la ausencia de relaciones lineales fuertes entre las variables y la variable objetivo.

Se han identificado correlaciones entre algunas variables derivadas, pero no se ha considerado necesario eliminarlas, dado que los modelos utilizados son robustos frente a la multicolinealidad.



8. Análisis exploratorio de datos

El análisis exploratorio ha permitido identificar patrones relevantes:

- Mayor gravedad en accidentes con peatones
- Mayor gravedad en ciertos tipos de accidente (atropellos, caídas, vuelcos)
- Influencia moderada de las condiciones meteorológicas
- Resultados no concluyentes en relación con el consumo de alcohol

El análisis se ha realizado sobre un periodo amplio (2019–2025), lo que aporta robustez a las conclusiones.

9. Visualización de las métricas en Power BI



Con el objetivo de facilitar la interpretación de los datos y extraer conclusiones relevantes desde el punto de vista de negocio, se ha desarrollado un dashboard interactivo en Power BI.

El objetivo principal del dashboard es:

Identificar los factores que aumentan la probabilidad de accidentes graves en Madrid, con el fin de mejorar la prevención y optimizar la asignación de recursos.

Estructura del dashboard

El dashboard se organiza en diferentes bloques que permiten analizar la gravedad de los accidentes desde distintas perspectivas:

- **Indicadores generales:**

Se muestran métricas agregadas como el número total de accidentes, el número de accidentes graves y el porcentaje de gravedad, lo que permite tener una visión global del problema.

- **Análisis geográfico:**

Se incluye un mapa que representa la distribución espacial de los accidentes, permitiendo identificar posibles concentraciones geográficas de la gravedad. Sin embargo, no se observa una concentración clara.

- **Impacto de condiciones meteorológicas:**

Se analiza la relación entre el clima y la gravedad, observándose una ligera mayor severidad en condiciones adversas como lluvia intensa.

- **Gravedad por tipo de accidente:**

Se identifican diferencias significativas entre tipos de accidente, destacando mayor gravedad en atropellos, caídas y vuelcos.

- **Análisis por tipo de implicado:**

Se observa que los peatones, especialmente en atropellos, presentan los niveles más altos de gravedad.

- **Variables contextuales:**

Se analizan factores como hora punta, festivos o consumo de alcohol, observándose que su impacto en la gravedad es limitado o no concluyente.

Interpretación y valor de negocio

El dashboard permite traducir los datos en información accionable, destacando que:

- Los factores estructurales (tipo de accidente y tipo de implicado) son los principales determinantes de la gravedad
- Las condiciones meteorológicas tienen un impacto moderado
- No existe una concentración geográfica clara que permita focalizar la intervención únicamente por ubicación

Desde una perspectiva de negocio, estos resultados permiten orientar estrategias de prevención hacia:

- Protección de usuarios vulnerables (peatones)
- Mejora de seguridad en tipos de accidente más críticos
- Optimización de recursos en función del riesgo esperado

10. Planteamiento de hipótesis

A partir del análisis exploratorio de los datos, se plantean las siguientes hipótesis que serán contrastadas posteriormente mediante el modelo de Machine Learning:

- Los accidentes con peatones presentan mayor gravedad
- El tipo de accidente influye en la gravedad
- Las condiciones meteorológicas aumentan la gravedad
- La hora punta incrementa la gravedad
- El consumo de alcohol aumenta la gravedad

11. Ingeniería de variables

Con el objetivo de mejorar la capacidad predictiva del modelo, se han aplicado distintas técnicas de

transformación sobre las variables originales del dataset.

Codificación de variables categóricas

Las variables categóricas han sido transformadas mediante **one-hot encoding**, permitiendo su utilización en modelos de Machine Learning. Entre las variables codificadas destacan:

- estado_meteorológico
- tipo_accidente
- tipo_persona
- vehiculo_grupo

Este proceso genera variables binarias que representan cada categoría, evitando introducir relaciones ordinales artificiales.

Agrupación de categorías de vehículos

La variable original de tipo de vehículo ha sido agrupada en categorías más generales (vehiculo_grupo) con el fin de:

- Reducir la dimensionalidad
- Mejorar la interpretabilidad
- Evitar dispersión en categorías poco frecuentes

Las principales agrupaciones incluyen:

- Vehículos ligeros
- Vehículos vulnerables (moto, bicicleta, patinete)
- Transporte público
- Otros

Generación de variables derivadas

Se han creado nuevas variables a partir de información temporal y contextual, con el objetivo de capturar patrones relevantes:

- hora_punta: indicador de horas de mayor tráfico
- fin_semana: identifica fines de semana
- festivo: identifica días festivos
- franja_horaria: agrupación de horas en tramos
- noche: indicador binario de conducción nocturna
- mes y estación: variables temporales

Estas variables permiten modelar efectos relacionados con el contexto temporal del accidente.

Generación de variables de interacción

Se han creado variables de interacción de forma no supervisada para capturar relaciones no lineales entre variables:

- noche_x_alcohol: interacción entre conducción nocturna y consumo de alcohol
- lluvia_x_hora: interacción entre precipitación y momento del día
- fin_semana_x_noche: combinación de contexto temporal y social
- hora_peligrosa: indicador de franjas horarias de mayor riesgo

Estas variables permiten al modelo identificar patrones más complejos que no serían capturados por las variables originales de forma independiente.

Variables espaciales mediante clustering

Se ha incorporado una variable de riesgo espacial (riesgo_zona) mediante técnicas de clustering (K-Means) aplicadas a las coordenadas geográficas (coordenada_x_utm, coordenada_y_utm).

Posteriormente, se ha calculado la gravedad media por zona utilizando únicamente el conjunto de entrenamiento, evitando *data leakage*, y se ha asignado este valor como indicador de riesgo espacial.

Prevención de *data leakage*

Durante el proceso de ingeniería de variables, se han aplicado medidas específicas para evitar el uso de información futura:

- Separación previa de datos en entrenamiento y test
- Cálculo de variables dependientes del target únicamente sobre el conjunto de entrenamiento
- Aplicación de estas transformaciones al conjunto de test sin utilizar su información real

Esto garantiza que la evaluación del modelo sea realista y no esté sesgada.

12. Modelado

Se han utilizado modelos de tipo ensemble basados en árboles, concretamente Random Forest y Gradient Boosting.

Se ha aplicado:

- Validación cruzada
- Ajuste de hiperparámetros
- Técnicas de balanceo de clases (SMOTE)

Asimismo, se ha optimizado el umbral de decisión con el objetivo de maximizar el F1-score.

Comparación de modelos

Con el objetivo de seleccionar el modelo más adecuado, se ha realizado una comparación entre los algoritmos Random Forest y Gradient Boosting, utilizando validación cruzada y como métrica principal el F1-score.

Los resultados obtenidos muestran que:

- Gradient Boosting: F1-score = 0.726
- Random Forest: F1-score = 0.717

A partir de estos resultados, se observa que Gradient Boosting presenta un rendimiento ligeramente superior en términos de F1-score.

Por este motivo, se selecciona este modelo como modelo final, al ofrecer un mejor equilibrio entre precisión y recall en el problema de clasificación.

13. Evaluación del modelo

	precision	recall	f1-score	support
0	0.61	0.56	0.58	3012
1	0.88	0.90	0.89	10497
accuracy			0.82	13509
macro avg	0.74	0.73	0.73	13509
weighted avg	0.82	0.82	0.82	13509

El modelo ha sido evaluado utilizando métricas de clasificación estándar como *precision*, *recall* y *F1-score*, con el objetivo de analizar su rendimiento tanto a nivel global como por clase.

Los resultados obtenidos son los siguientes:

- Accuracy global: 0.82
- F1-score macro: 0.73
- F1-score ponderado: 0.82
-

Análisis por clase

Clase 0 (accidentes no graves)

- Precision: 0.61
- Recall: 0.56
- F1-score: 0.58

El modelo presenta un rendimiento moderado en la identificación de accidentes no graves. El valor relativamente bajo de *recall* (0.56) indica que una parte significativa de estos accidentes está siendo clasificada erróneamente como graves.

Clase 1 (accidentes graves)

- Precision: 0.88
- Recall: 0.90
- F1-score: 0.89

El modelo muestra un rendimiento elevado en la detección de accidentes graves. El alto valor de *recall* (0.90) indica que el modelo es capaz de identificar correctamente la mayoría de los accidentes graves, lo cual es especialmente relevante desde el punto de vista operativo.

Interpretación global

El modelo presenta un mejor desempeño en la clase mayoritaria (accidentes graves), lo que se refleja en un F1-score elevado para esta clase. Sin embargo, su capacidad para identificar correctamente accidentes no graves es más limitada.

La diferencia entre el F1-score macro (0.73) y el ponderado (0.82) sugiere la existencia de desbalanceo en las clases, donde el modelo tiende a favorecer la clase con mayor representación.

Implicaciones prácticas

Desde una perspectiva de negocio, este comportamiento puede considerarse adecuado, ya que:


- Se prioriza la correcta detección de accidentes graves
- Se minimiza el riesgo de no identificar situaciones críticas (falsos negativos en clase grave)

No obstante, el modelo tiende a sobreestimar la gravedad en algunos casos, clasificando accidentes no graves como graves (falsos positivos), lo que podría generar una asignación ineficiente de recursos si no se ajusta adecuadamente.

Conclusión

En conjunto, el modelo presenta un rendimiento sólido, especialmente en la detección de accidentes graves. Sin embargo, existe margen de mejora en la discriminación de accidentes no graves, lo que podría abordarse mediante ajustes adicionales en el modelo o en el umbral de decisión.

14. Análisis de la matriz de confusión



La matriz de confusión muestra los siguientes resultados:

- Verdaderos negativos (TN): 1684
- Falsos positivos (FP): 1328
- Falsos negativos (FN): 1086
- Verdaderos positivos (TP): 9411

El modelo presenta una alta capacidad para identificar accidentes graves, reflejada en el elevado número de verdaderos positivos, lo que es consistente con el alto *recall* de esta clase.

Sin embargo, se observan errores relevantes:

- Un número considerable de falsos positivos, lo que implica una sobreestimación de la gravedad en algunos casos

- Falsos negativos, que representan accidentes graves no detectados

Desde el punto de vista operativo, los falsos negativos son los más críticos, aunque su número es inferior al de verdaderos positivos, lo que indica que el modelo prioriza correctamente la detección de casos graves.

En conjunto, el modelo muestra un comportamiento adecuado para el problema, al priorizar la identificación de accidentes graves, aunque con margen de mejora en la clasificación de accidentes no graves.

15. Validación de hipótesis

Las hipótesis planteadas inicialmente se contrastan mediante la combinación del análisis exploratorio de datos (EDA) y los resultados del modelo de Machine Learning, especialmente el análisis de importancia de variables.

• Los accidentes con peatones presentan mayor gravedad: Confirmada

El análisis exploratorio muestra que los accidentes que involucran peatones presentan los valores más elevados de gravedad media, especialmente en casos de atropello. Este resultado se ve reforzado por el modelo, donde las variables relacionadas con el tipo de implicado (peatón) aparecen entre las más relevantes.

Esto indica que la vulnerabilidad del peatón es un factor determinante en la severidad del accidente.

• El tipo de accidente influye en la gravedad: Confirmada

El EDA evidencia diferencias significativas en la gravedad según el tipo de accidente, siendo los más graves los atropellos, caídas y vuelcos. Esta relación también se refleja en el modelo, donde variables asociadas al tipo de accidente o al tipo de vehículo (especialmente motocicletas) presentan una alta importancia.

Esto confirma que la naturaleza del accidente es uno de los principales determinantes de su gravedad.

• Las condiciones meteorológicas influyen en la gravedad: Parcialmente confirmada

El análisis exploratorio muestra una ligera mayor gravedad en condiciones meteorológicas adversas, como lluvia intensa o nieve. Sin embargo, el modelo no asigna una alta importancia a estas variables, lo que sugiere que su capacidad predictiva es limitada.

Esto indica que el clima puede influir en la gravedad, pero su efecto es secundario frente a otros factores más determinantes.

• La hora punta aumenta la gravedad: No confirmada

Los resultados del EDA muestran que la gravedad media de los accidentes es ligeramente inferior durante las horas punta. Este resultado se ve respaldado por el modelo, donde las variables relacionadas con la hora no aparecen como factores relevantes.

Esto sugiere que una mayor densidad de tráfico no implica necesariamente accidentes más graves, posiblemente debido a velocidades más reducidas.

• El consumo de alcohol incrementa la gravedad: No confirmada en el dataset

De forma contraintuitiva, el análisis exploratorio muestra que los accidentes con alcohol positivo presentan una gravedad media inferior. Además, esta variable no aparece entre las más importantes

en el modelo.

Este resultado puede estar influido por factores como el subregistro de casos, sesgos en los datos o la presencia de variables correlacionadas que capturan indirectamente este efecto. Por tanto, aunque no se confirma en el dataset, no puede descartarse su relevancia en un contexto real.

En conjunto, los resultados muestran que la gravedad de los accidentes está principalmente determinada por factores estructurales, como el tipo de implicado y el tipo de accidente, mientras que variables contextuales como el clima, la hora o el consumo de alcohol tienen un impacto menor o no concluyente en este análisis.

16. Conclusiones

Los resultados indican que la gravedad de los accidentes está principalmente determinada por factores estructurales, como el tipo de implicado y el tipo de vehículo.

Las variables contextuales tienen un impacto menor en el conjunto de datos analizado.

El modelo desarrollado constituye una base sólida, aunque mejorable en la identificación de accidentes graves.

17. Posibles mejoras

- **Mejora en la clasificación de accidentes no graves**
El modelo muestra menor rendimiento en esta clase (F1-score 0.58), por lo que se podrían ajustar técnicas de balanceo para mejorar su discriminación.
- **Mejora del modelado con algoritmos más avanzados**
Explorar modelos como XGBoost o LightGBM, que suelen ofrecer mejor rendimiento en problemas tabulares complejos.
- **Ampliación y enriquecimiento del dataset**
Incluir más años históricos o fuentes adicionales para reducir sesgos y mejorar la representatividad, especialmente en variables como alcohol o clima, donde los resultados no han sido concluyentes.
- **Validación más robusta del modelo**
Actualmente el modelo se ha validado mediante partición aleatoria, pero como mejora futura se propone aplicar validación temporal, entrenando con datos históricos y evaluando en periodos posteriores, con el objetivo de analizar la capacidad del modelo para generalizar en escenarios reales.
- **Aplicación práctica en entorno real**
Integrar el modelo en sistemas operativos que permitan:
 - Priorizar recursos sanitarios
 - Identificar zonas de alto riesgo
 - Apoyar decisiones en tiempo real
- **Escalabilidad e integración en entornos productivos**
Como evolución del proyecto, el modelo podría integrarse en sistemas productivos o desplegarse en la nube para facilitar su escalabilidad y uso operativo. Dado que el enfoque actual es batch con datos históricos, no se ha considerado necesario implementar una arquitectura en tiempo real.

18. Lessons Learned

A lo largo del desarrollo del proyecto se han identificado diversos aprendizajes clave, especialmente en el ámbito del procesamiento técnico de los datos y el modelado.

Procesamiento de datos

En primer lugar, se detectó un error en la incorporación de la variable de **festivo**, debido a una incompatibilidad en el formato de los datos (tipo fecha). Esta situación provocaba una incorrecta identificación de los días festivos al integrarlos en el dataset principal.

Este problema puso de manifiesto la importancia de validar cuidadosamente el formato de las variables antes de realizar procesos de integración. Una incorrecta alineación de formatos puede derivar en errores silenciosos que afectan directamente a la calidad de los datos y, por tanto, al rendimiento del modelo.

Gestión del desbalanceo y data leakage

En segundo lugar, se trabajó con técnicas de *data augmentation* para abordar el problema del desbalanceo de clases, concretamente mediante el uso de **SMOTE**.

Inicialmente, SMOTE fue aplicado antes del proceso de validación cruzada, lo que introducía un problema de *data leakage*, ya que se generaban muestras sintéticas utilizando información de todo el dataset.

Tras identificar este problema, se corrigió el enfoque incorporando SMOTE dentro del pipeline de validación cruzada. De este modo, el oversampling se aplica únicamente sobre los datos de entrenamiento en cada iteración, evitando el uso de información del conjunto de test y garantizando una evaluación más realista del modelo.

Definición de la variable objetivo

Por último, se aprendió la importancia crítica de una adecuada definición de la variable objetivo (*target*).

Inicialmente, se planteó un enfoque de clasificación multiclase (tres niveles de gravedad). Sin embargo, el modelo mostraba dificultades para distinguir entre los distintos niveles, especialmente entre gravedad leve y gravedad alta.

Ante esta limitación, se optó por una reformulación del problema hacia una clasificación binaria:

- Clase 0: accidentes sin asistencia sanitaria
- Clase 1: accidentes con cualquier tipo de asistencia sanitaria

Esta nueva definición permitió mejorar significativamente el rendimiento del modelo, además de aportar un mayor valor desde el punto de vista de negocio, ya que permite responder a una pregunta clave: si un accidente tiene probabilidad de requerir recursos médicos.